

Learning Urban Crime Representations to Detect Reporting Disparities

Prof. Dr. Jorge Valverde-Rebaza

1. Descripción del proyecto

Se propone una investigación orientada al aprendizaje de representaciones urbanas a partir del conjunto público de carpetas de investigación de la Fiscalía General de Justicia de la Ciudad de México. Este dataset contiene información histórica desde enero de 2016 e incluye variables de fecha, tipo de delito, ubicación, colonia, alcaldía y coordenadas geográficas, con actualizaciones periódicas en el portal de datos abiertos de la ciudad.

La propuesta parte de dos características críticas del conjunto de datos. En primer lugar, las categorías delictivas contienen una cantidad significativa de ruido semántico, debido a errores ortográficos, variantes de escritura, duplicados conceptuales y registros humanos poco consistentes. En segundo lugar, como ocurre con gran parte de los registros policiales, el dataset no representa necesariamente el crimen “real”, sino el crimen reportado y registrado, lo cual puede introducir sesgos espaciales y sociales en el análisis. La literatura ha señalado que este tipo de sesgo puede afectar de manera importante los análisis geográficos del crimen, especialmente cuando se trabaja a escalas espaciales pequeñas.

En este contexto, la propuesta no se centra en la predicción del crimen, sino en un objetivo metodológicamente más sólido y potencialmente más publicable: aprender embeddings de zonas urbanas robustos al ruido del registro policial y utilizarlos tanto para visualizar la estructura funcional de la ciudad como para detectar señales de discordancia en el reporte entre zonas similares. Esta formulación permite generar conocimiento útil para análisis urbano, calidad del dato y equidad territorial, sin afirmar de manera causal la existencia de subreporte real, sino identificando patrones persistentes de discrepancia observada.

2. Objetivo general

Construir representaciones urbanas robustas a registros policiales ruidosos y utilizarlas para dos fines complementarios:

O1: visualizar e interpretar la estructura latente del crimen reportado en la ciudad, y

O2: detectar señales de disparidad o discordancia en el reporte del crimen entre zonas urbanamente comparables.

3. Justificación e impacto

Aunque los datasets policiales de la FGJ de CDMX (<https://datos.cdmx.gob.mx/dataset/carpetas-de-investigacion-fgj-de-la-ciudad-de-mexico>) han sido ampliamente estudiados, con frecuencia se utilizan de forma descriptiva o predictiva, sin atender suficientemente al problema del ruido semántico en las etiquetas (columna categoría/tipo de delito) ni a la necesidad de aprender representaciones más robustas del espacio urbano. Al integrar limpieza semántica, aprendizaje de representaciones y análisis de

discordancia de reporte, esta propuesta busca situarse en la intersección entre tres líneas relevantes: label noise, urban region representation learning y social bias en estadísticas policiales.

Desde una perspectiva aplicada, el proyecto aporta en:

- mejorar la calidad analítica del dato policial,
- construir tipologías funcionales de zonas urbanas,
- visualizar similitudes y diferencias entre territorios,
- e identificar áreas donde el patrón observado de reporte resulta discordante respecto de otras zonas comparables/semajantes.

El impacto práctico radica en que los resultados podrían ser útiles para analistas de seguridad, investigadores urbanos y entidades públicas interesadas en comprender mejor la heterogeneidad territorial del dato administrativo. Al mismo tiempo, el enfoque sería transferible a otros contextos latinoamericanos donde existen problemas similares de clasificación manual y heterogeneidad institucional.

4. Pregunta de investigación

La pregunta central de la propuesta sería la siguiente: *¿Es posible aprender representaciones urbanas robustas a categorías delictivas ruidosas y utilizarlas para visualizar la estructura funcional del crimen reportado e identificar zonas cuyo patrón registrado resulte discordante respecto a otras zonas similares?*

5. Metodología propuesta

La investigación se desarrollaría en cinco etapas.

5.1. Armonización semántica de categorías delictivas: se concentraría en la limpieza y consolidación de las categorías delictivas. Dado que el conjunto presenta numerosas variantes manuales de la misma categoría de delito, se propone construir una taxonomía canónica en dos niveles: macro-categorías robustas y categorías específicas limpias. Para ello se combinarían:

- métodos de ML clásico, como TF-IDF a nivel de caracteres o palabras, similitud coseno, Levenshtein, Jaro-Winkler y clustering jerárquico;
- métodos de Deep Learning/NLP, como embeddings semánticos con Sentence-BERT o LaBSE, útiles para agrupar etiquetas cortas con ruido;
- uso auxiliar de LLMs, exclusivamente para revisión de fusiones ambiguas, propuesta de nombres canónicos y apoyo en la interpretación de grupos de etiquetas. Su uso es opcional y bajo aprobación del profesor para no introducir variabilidad en los resultados.

Esta fase permitiría reducir la cardinalidad artificial del espacio de categorías y controlar uno de los principales factores que podrían contaminar cualquier análisis posterior.

5.2. Construcción de firmas espacio-temporales por zona: En una segunda etapa, el territorio urbano se discretizaría en unidades analíticas comparables, por ejemplo mediante una malla regular o celdas H3,

manteniendo además agregaciones por colonia o alcaldía para interpretación externa. Para cada unidad espacial se construiría una firma delictiva compuesta por: mezcla de delitos, intensidad relativa, perfiles horarios, distribución semanal, estacionalidad y persistencia temporal.

El propósito no sería solo contar incidentes, sino representar cada zona como un objeto multivista que describa su comportamiento reportado a lo largo del tiempo.

5.3. Aprendizaje de representaciones urbanas: La tercera etapa sería el núcleo metodológico del proyecto. A partir de las firmas espacio-temporales se aprendería un embedding para cada zona urbana. La propuesta contempla comparar métodos de distinta complejidad.

Como línea base se emplearían métodos de ML clásico como PCA, NMF, K-means, Gaussian Mixture Models y HDBSCAN. Como modelos más avanzados se considerarían autoencoders densos, Graph Autoencoders o Variational Graph Autoencoders.

En esta propuesta, el embedding no sería entendido únicamente como una entrada para clasificación o detección de anomalías. También se asumiría como una representación visualizable del espacio urbano. Mediante proyecciones como PCA, t-SNE o UMAP (que es uno de los mejores en los últimos tiempos), los embeddings podrían transformarse en mapas 2D o 3D que permitan observar clústeres, gradientes, zonas aisladas y continuidad entre perfiles urbanos.

5.4. Visualización e interpretación del espacio latente: Esta etapa sería explícitamente una contribución del proyecto. Los embeddings aprendidos se utilizarían para construir dos tipos de visualización complementaria.

La primera sería una visualización abstracta del espacio latente, en la que cada punto represente una zona de la ciudad. Estas proyecciones permitirían identificar agrupamientos funcionales, zonas de transición y puntos atípicos. La segunda sería una visualización geográfica, en la que los clusters, scores o coordenadas derivadas del embedding se proyecten nuevamente sobre el mapa real de la ciudad. Con ello se buscaría responder no solo “qué zonas son similares”, sino también “dónde están ubicadas” y “qué patrón urbano representan”.

Esta combinación entre espacio latente y espacio geográfico fortalecería la interpretabilidad del modelo y diferenciaría la propuesta de enfoques puramente técnicos orientados a clasificación.

5.5. Detección de señales de disparidad en el reporte: Finalmente, cada zona sería comparada con sus pares más cercanos en el espacio de embeddings. La hipótesis operativa sería que zonas funcionalmente similares deberían exhibir patrones de reporte razonablemente próximos. Aquellas zonas cuyo volumen, composición o ritmo temporal reportado se aparten persistentemente de lo esperado podrían considerarse candidatas a discordancia de reporte. Aquí, se espera utilizar:

- ML clásico: kNN regression, Random Forest, Quantile Regression Forest o XGBoost para estimar perfiles geoespaciales esperados;
- detección de anomalías: Isolation Forest y Local Outlier Factor;
- Deep Learning: autoencoders de reconstrucción o Deep SVDD para detección de zonas anómalas;

- LLMs: generación de descripciones interpretativas automáticas para explicar por qué una zona aparece como discordante, sin que el LLM sea el núcleo del método. Esto sería opcional y bajo aprobación del profesor responsable.

6. Resultados esperados

Se espera que la investigación produzca:

- una taxonomía delictiva más estable y reproducible;
- embeddings urbanos con capacidad tanto analítica como visual;
- tipologías funcionales de zonas urbanas basadas en crimen reportado;
- mapas de similitud y de discordancia de reporte;
- evidencia de que la limpieza semántica y el aprendizaje de representaciones modifican de manera sustantiva la lectura del fenómeno espacial.

7. Diferencial científico y potencial de publicación

El principal diferencial del proyecto radica en que no aborda el dataset únicamente como un insumo para predicción o descripción, sino como un problema de representación robusta bajo ruido semántico, con una salida doble: visualización interpretable y detección de discordancias territoriales. Esta combinación es menos frecuente en la literatura que los enfoques clásicos de hotspot analysis o forecasting.

Además, mientras muchos trabajos de urban embeddings dependen de fuentes multimodales como movilidad, POIs o imágenes, esta propuesta exploraría hasta qué punto un solo registro administrativo (y en formato textual), aun siendo ruidoso, puede producir representaciones útiles si se trabaja adecuadamente. Ese detalle constituye una contribución transferible a otros dominios de análisis de datos públicos.

Referencias

Buil-Gil, D., Moretti, A., & Langton, S. The accuracy of crime statistics: assessing the impact of police data bias on geographic crime analysis. *Journal of Experimental Criminology*, pp. 515-541, 2022. (<https://link.springer.com/article/10.1007/s11292-021-09457-y>)

Jindal, I., Pressel, D., Lester, B., & Nokleby, M. An Effective Label Noise Model for DNN Text Classification. NAACL-HLT, 2019. (<https://aclanthology.org/N19-1328/>)

Álvaro J. Riascos Villegas, et al. Modelling underreported spatio-temporal crime events. *PLOS ONE*, 2023. (<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0287776>)

McInnes, L., Healy, J., & Melville, J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv/JOSS* (<https://arxiv.org/pdf/1802.03426>)